



Estudiantes:

Keylor Herrera Fuentes

2021046723

Esteban Daniel Secaida Vargas

2019042589

Alisson Rodríguez Reyes

2021083026

Bases de Datos II.

Grupo 20.

Profesor:

Alberto Shum Chan

Proyecto 3

Big Data

Fecha de entrega: 22/06/2025

Descripción del Sistema	3
Instalación y Configuración	3
Procesos ETL	4
Carga de Datos	4
Limpieza y Transformación	5
Integración de Datos	5
Carga en PostgreSQL (Supabase)	5
Visualizaciones Generadas	6
Delitos vs Tasa de Ocupación (Top 10 distritos)	6
Delitos por Día en el Distrito con más Incidentes	7
Delitos por Tipo en un Distrito	7
Delitos por Género	8
Visualización Adicional Propuesta	9
Funciones ETL Desarrolladas	10
Conclusiones	13
Bibliografía	14

Descripción del Sistema

Este proyecto tiene como propósito aplicar técnicas de **extracción, transformación y carga (ETL)** usando **Apache SparkSQL**. Los datos utilizados provienen de dos fuentes oficiales:

1. **INEC** (Instituto Nacional de Estadística y Censos): indicadores socioeconómicos obtenidos del Censo Nacional 2011.
2. **OIJ** (Organismo de Investigación Judicial): estadísticas de criminalidad registradas durante el año 2011.

La solución desarrollada permite **limpiar, integrar, almacenar y analizar** ambos conjuntos de datos con el fin de obtener visualizaciones que permitan identificar relaciones entre la criminalidad y variables socioeconómicas a nivel distrital.

El desarrollo se realizó completamente en **Google Colab** por su facilidad de configuración y soporte para Spark. Los datos finales fueron cargados a una base de datos PostgreSQL alojada en **Supabase**, lo cual permite una posible consulta externa o integración futura. Las visualizaciones fueron implementadas con matplotlib y seaborn.

Instalación y Configuración

El entorno de trabajo utilizado fue **Google Colab**, aprovechando su compatibilidad con bibliotecas de Big Data como Apache Spark. Las herramientas y versiones fueron las siguientes:

Componente	Versión / Configuración
Apache Spark	3.5.0
Java (OpenJDK)	8
Python	3.x (Colab default)
PostgreSQL	Supabase (versión en la nube)
Bibliotecas adicionales	pyspark, psycopg2, sqlalchemy, matplotlib, seaborn

Configuración en Colab:

```
os.environ['SPARK_HOME'] = "/content/spark-3.5.0-bin-hadoop3"
```

```
os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
```

Conexión a PostgreSQL Supabase:

```
DATABASE_URL = 'postgresql+psycopg2://usuario:contraseña@host:puerto/db'
```

Se utilizó SQLAlchemy para abstraer la conexión y permitir escritura directa desde DataFrames.

Procesos ETL

Carga de Datos

Los datasets fueron descargados desde las fuentes oficiales:

- **INEC**: Indicadores de empleo y economía por distrito, provenientes del Censo 2011.
- **OIJ**: Denuncias criminales desglosadas por tipo de delito, género, edad, ubicación, fecha y hora.

Ambos archivos se leyeron usando:

```
spark.read.option("header", True).csv("archivo.csv")
```

Limpieza y Transformación

Dado que los nombres de distrito no coincidían en ambos datasets, se desarrolló una serie de funciones para normalizarlos:

- **Eliminar espacios en blanco innecesarios**
- **Convertir texto a minúsculas**
- **Detectar y listar distritos que no coinciden**
- **Corregir nombres mediante mapeo condicional (when)**

Este proceso fue crucial para garantizar una integración exitosa, ya que los join en SparkSQL son sensibles a las diferencias de formato.

Integración de Datos

Los datos normalizados fueron integrados por el campo `distrito_normalizado` mediante una consulta SQL:

```
SELECT o.*, i.*  
FROM oij_data o  
JOIN inec_data i  
ON o.distrito_normalizado = i.distrito_normalizado
```

Este paso permitió combinar indicadores sociales y económicos con los registros de delitos para cada distrito del país.

Carga en PostgreSQL (Supabase)

Luego de la limpieza y transformación, ambos conjuntos fueron almacenados en una base de datos relacional PostgreSQL en Supabase usando el método:

```
df.write.jdbc(url=DATABASE_URL, table="datos_oij_limpios", mode="overwrite")
```

Tablas generadas:

- datos_oij_limpios
- datos_inec_limpios


Esto garantiza persistencia, escalabilidad y la posibilidad de hacer consultas externas o usar herramientas BI.

Visualizaciones Generadas

Delitos vs Tasa de Ocupación

Se visualizó la relación entre el número de delitos y la tasa de ocupación, revelando tendencias entre criminalidad y empleo.


Herramientas: matplotlib, seaborn, join + groupBy



Delitos por Día (Distrito con más Incidentes)

Identificación de los días con mayor actividad delictiva en el distrito más conflictivo del país.


Se usó la función `dayofweek()` para extraer el día a partir de la fecha



Delitos por Tipo (en un distrito seleccionado)

Análisis del tipo de delitos más frecuentes en un distrito específico.


Uso de `groupBy` sobre la columna `Delito`.



Delitos por Género

Distribución de las víctimas por sexo a nivel nacional.


Representado mediante gráfico de barras (count() + filter()) por género).



Visualización Propuesta

Heatmap que muestra la frecuencia de delitos por franja horaria y género de las víctimas.

Matriz dinámica + pivot + seaborn.heatmap()



Funciones ETL Desarrolladas

eliminar_espacios(df, columna)

- Elimina espacios extras con `regexp_replace`

convertir_minusculas(df, columna)

- Convierte strings a minúsculas con `lower()`


obtener_distritos_no_coincidentes(df1, df2)

- Devuelve lista de nombres de distrito del OIJ no presentes en INEC

cantidad_distritos_no_coincidentes(df1, df2)


- Cuenta cuántos registros del OIJ no se pueden vincular con INEC

Aca adjunto informacion sobre la base creada en SupaBase.



The screenshot shows the Supabase Table Editor interface for the 'oi_j_inec' table. The table has 100 rows and 6 columns: Distrito, Delito, SubDelito, Fecha, and Hora. The data is filtered to show the first 100 rows. The interface includes a sidebar with navigation options like Project overview, Table Editor, SQL Editor, Database, Authentication, Storage, Edge Functions, Realtime, Advisors, Reports, Logs, API Docs, Integrations, and Project Settings. The table data is as follows:

Distrito	Delito	SubDelito	Fecha	Hora
acapulco	ROBO DE VEHICULO	ASALTO	2011-07-15	18:00:00 - 20:59:59
acapulco	ROBO	FORZADURA	2011-10-21	00:00:00 - 02:59:59
acapulco	ROBO	FORZADURA	2011-11-15	12:00:00 - 14:59:59
aguas claras	ROBO	FORZADURA	2011-06-21	18:00:00 - 20:59:59
aguas claras	ROBO	FORZADURA	2011-03-18	00:00:00 - 02:59:59
aguas claras	ASALTO	ARMA BLANCA	2011-10-17	21:00:00 - 23:59:59
aguas claras	ASALTO	ARMA DE FUEGO	2011-01-19	18:00:00 - 20:59:59
aguas claras	ROBO	QUITAN CELOSIAS	2011-01-24	00:00:00 - 02:59:59
aguas claras	ROBO	BOQUETE	2011-03-21	21:00:00 - 23:59:59
aguas claras	HURTO	POR CONFIANZA	2011-09-11	00:00:00 - 02:59:59
aguas claras	ASALTO	INMOVILIZACION	2011-01-05	09:00:00 - 11:59:59
aguas claras	ROBO	CORTA CANDADOS	2011-03-04	00:00:00 - 02:59:59
aguas claras	ROBO	FORZADURA	2011-05-12	00:00:00 - 02:59:59
aguas claras	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-04-23	00:00:00 - 02:59:59



The screenshot shows the Supabase Table Editor interface for the 'oi_j_inec' table. The table has 100 rows and 6 columns: Distrito, Delito, SubDelito, Fecha, and Hora. The data is filtered to show the first 100 rows. The interface includes a sidebar with navigation options like Project overview, Table Editor, SQL Editor, Database, Authentication, Storage, Edge Functions, Realtime, Advisors, Reports, Logs, API Docs, Integrations, and Project Settings. The table data is as follows:

Distrito	Delito	SubDelito	Fecha	Hora
aguas claras	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-04-23	00:00:00 - 02:59:59
aguas claras	ROBO	FORZADURA	2011-07-03	18:00:00 - 20:59:59
aguas claras	ROBO DE VEHICULO	DESCUIDO	2011-07-24	00:00:00 - 02:59:59
aguas claras	HURTO	ARDID PREVIO/DISTRACCION	2011-03-29	18:00:00 - 20:59:59
aguas claras	ROBO	CORTA CANDADOS	2011-11-04	09:00:00 - 11:59:59
aguas claras	ROBO	FORZADURA	2011-11-18	00:00:00 - 02:59:59
aguas claras	HURTO	POR CONFIANZA	2011-06-30	00:00:00 - 02:59:59
aguas claras	ROBO	FORZADURA	2011-03-04	00:00:00 - 02:59:59
aguas claras	ROBO	FORZADURA	2011-09-18	18:00:00 - 20:59:59
aguas claras	ROBO	RUPTURA VENTANA	2011-01-18	12:00:00 - 14:59:59
aguas claras	ROBO	BOQUETE	2011-12-03	18:00:00 - 20:59:59
aguas zarcas	ASALTO	ARMA DE FUEGO	2011-04-19	15:00:00 - 17:59:59
aguas zarcas	ASALTO	GOLPES	2011-09-23	18:00:00 - 20:59:59
aguas zarcas	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-06-28	00:00:00 - 02:59:59

Alit3200's OrgFreeAlit3200's ProjectConnectEnable branchingFeedback

Table Editor

schema publicNew tableSearch tables...ojj_incecusuarios

ojj_incec

FilterSortInsert

RLS disabledRollbackpostgresRealtime offAPI Docs

	Distrito text	Delito text	SubDelito text	Fecha text	Hora text
	aguas zarcas	ROBO	FORZADURA	2011-09-03	15:00:00 - 17:59:59
	aguas zarcas	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-05-15	00:00:00 - 02:59:59
	aguas zarcas	ROBO DE VEHICULO	ASALTO	2011-11-01	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-01-27	21:00:00 - 23:59:59
	aguas zarcas	ROBO DE VEHICULO	POR CONFIANZA	2011-03-25	21:00:00 - 23:59:59
	aguas zarcas	ROBO	FORZADURA	2011-04-04	15:00:00 - 17:59:59
	aguas zarcas	ASALTO	ARMA BLANCA	2011-07-19	18:00:00 - 20:59:59
	aguas zarcas	ROBO	FORZADURA	2011-06-16	06:00:00 - 08:59:59
	aguas zarcas	ROBO DE VEHICULO	COCHERAZO	2011-03-14	00:00:00 - 02:59:59
	aguas zarcas	ROBO	RUPTURA VENTANA	2011-03-29	09:00:00 - 11:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-07-12	06:00:00 - 08:59:59
	aguas zarcas	ROBO	RUPTURA VENTANA	2011-10-31	15:00:00 - 17:59:59
	aguas zarcas	HURTO	CON LLAVE	2011-11-25	15:00:00 - 17:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-04-26	21:00:00 - 23:59:59

Page 1 of 903100 rows90.2K records (estimated)RefreshDataDefinition

Alit3200's OrgFreeAlit3200's ProjectConnectEnable branchingFeedback

Table Editor

schema publicNew tableSearch tables...ojj_incecusuarios

ojj_incec

FilterSortInsert

RLS disabledRollbackpostgresRealtime offAPI Docs

	Distrito text	Delito text	SubDelito text	Fecha text	Hora text
	aguas zarcas	ROBO	FORZADURA	2011-01-22	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-08-08	15:00:00 - 17:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-03-08	18:00:00 - 20:59:59
	aguas zarcas	ROBO DE VEHICULO	DESCUIDO	2011-09-04	03:00:00 - 05:59:59
	aguas zarcas	ROBO	FORZADURA	2011-08-29	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-03-01	06:00:00 - 08:59:59
	aguas zarcas	HURTO	POR CONFIANZA	2011-03-03	00:00:00 - 02:59:59
	aguas zarcas	ROBO	CORTA CANDADOS	2011-01-26	00:00:00 - 02:59:59
Expand row	aguas zarcas	HURTO	POR CONFIANZA	2011-04-09	21:00:00 - 23:59:59
	aguas zarcas	ROBO	CORTA CANDADOS	2011-01-15	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-01-21	00:00:00 - 02:59:59
	aguas zarcas	HURTO	POR DESCUIDO	2011-01-08	18:00:00 - 20:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-02-21	00:00:00 - 02:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-04-26	00:00:00 - 02:59:59

Page 1 of 903100 rows90.2K records (estimated)RefreshDataDefinition

Alit3200's OrgFreeAlit3200's ProjectConnectEnable branchingFeedback

Editor

publicNew tableSearch tables...ojj_incecusuarios

ojj_incec

FilterSortInsert

RLS disabledRollbackpostgresRealtime offAPI Docs

	Distrito text	Delito text	SubDelito text	Fecha text	Hora text
	aguas zarcas	HURTO	POR CONFIANZA	2011-06-20	00:00:00 - 02:59:59
	aguas zarcas	ROBO DE VEHICULO	DESCUIDO	2011-08-05	00:00:00 - 02:59:59
	aguas zarcas	ROBO DE VEHICULO	DESCUIDO	2011-10-04	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-03-13	18:00:00 - 20:59:59
	aguas zarcas	ASALTO	GOLPES	2011-09-23	18:00:00 - 20:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-11-01	12:00:00 - 14:59:59
	aguas zarcas	ROBO	QUITAN CELOSIAS	2011-09-14	15:00:00 - 17:59:59
	aguas zarcas	ASALTO	ARMA DE FUEGO	2011-04-19	15:00:00 - 17:59:59
	aguas zarcas	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-06-28	00:00:00 - 02:59:59
	aguas zarcas	HURTO	POR CONFIANZA	2011-06-24	00:00:00 - 02:59:59
	aguas zarcas	HURTO	POR CONFIANZA	2011-07-29	18:00:00 - 20:59:59
	aguas zarcas	ROBO DE VEHICULO	DESCUIDO	2011-12-09	00:00:00 - 02:59:59
	aguas zarcas	ROBO DE VEHICULO	POR CONFIANZA	2011-05-30	00:00:00 - 02:59:59
	aguas zarcas	ROBO	FORZADURA	2011-02-27	21:00:00 - 23:59:59

Page 1 of 903100 rows90.2K records (estimated)RefreshDataDefinition

Distrito	Delito	SubDelito	Fecha	Hora
aguas zacaras	ASALTO	ARMA BLANCA	2011-04-17	12:00:00 - 14:59:59
aguas zacaras	ROBO	FORZADURA	2011-09-09	12:00:00 - 14:59:59
aguas zacaras	ASALTO	ARMA BLANCA	2011-05-15	18:00:00 - 20:59:59
aguas zacaras	ROBO DE VEHICULO	DESCUIDO	2011-04-09	00:00:00 - 02:59:59
aguas zacaras	ROBO DE VEHICULO	DESCUIDO	2011-04-29	21:00:00 - 23:59:59
aguas zacaras	HURTO	CON LLAVE	2011-06-15	00:00:00 - 02:59:59
aguas zacaras	ASALTO	ARMA DE FUEGO	2011-01-13	21:00:00 - 23:59:59
aguas zacaras	HURTO	CON LLAVE	2011-05-23	15:00:00 - 17:59:59
aguas zacaras	ASALTO	INTIMIDACION VERBAL	2011-12-30	21:00:00 - 23:59:59
aguas zacaras	ASALTO	GOLPES	2011-03-27	21:00:00 - 23:59:59
aguas zacaras	HURTO	CON LLAVE	2011-12-26	09:00:00 - 11:59:59
aguas zacaras	HURTO	POR CONFIANZA	2011-05-24	18:00:00 - 20:59:59
aguas zacaras	HURTO	POR CONFIANZA	2011-05-31	00:00:00 - 02:59:59
aguas zacaras	ROBO	CORTA CANDADOS	2011-02-21	00:00:00 - 02:59:59

Distrito	Delito	SubDelito	Fecha	Hora
aguas zacaras	HURTO	POR CONFIANZA	2011-05-31	00:00:00 - 02:59:59
aguas zacaras	ROBO	CORTA CANDADOS	2011-02-21	00:00:00 - 02:59:59
aguas zacaras	HURTO	POR DESCUIDO	2011-12-15	12:00:00 - 14:59:59
aguas zacaras	ROBO	ESCALAMIENTO	2011-01-30	00:00:00 - 02:59:59
aguas zacaras	ROBO	FORZADURA	2011-05-25	00:00:00 - 02:59:59
aguas zacaras	HURTO	POR DESCUIDO	2011-03-04	00:00:00 - 02:59:59
aguas zacaras	HURTO	CON LLAVE	2011-12-31	18:00:00 - 20:59:59
aguas zacaras	HURTO	POR DESCUIDO	2011-08-18	12:00:00 - 14:59:59
aguas zacaras	ROBO	FORZADURA	2011-01-27	21:00:00 - 23:59:59
aguas zacaras	ROBO	FORZADURA	2011-07-18	15:00:00 - 17:59:59
aguas zacaras	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-05-15	00:00:00 - 02:59:59
aguas zacaras	ASALTO	ARMA BLANCA	2011-05-15	18:00:00 - 20:59:59
aguas zacaras	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-05-15	00:00:00 - 02:59:59
aguas zacaras	TACHA DE VEHICULO	TACHA DE VEHICULO	2011-04-22	00:00:00 - 02:59:59

Conclusiones

La limpieza de datos es crítica en proyectos reales: pequeñas diferencias en nombres de campo pueden impedir la integración.

Los datos muestran patrones socioeconómicos importantes: distritos con baja ocupación y mayor desempleo tienden a registrar más delitos.

Apache Spark es altamente eficiente para el procesamiento de grandes volúmenes, incluso en entornos como Google Colab.

Las visualizaciones ayudan a transformar datos en conocimiento: permiten inferir relaciones y patrones útiles para políticas públicas.

Bibliografía

1. Instituto Nacional de Estadísticas y Censos (INEC). (2011). *Censo 2011*.
<https://admin.inec.cr>
2. Organismo de Investigación Judicial (OIJ). (2018). *Estadísticas Policiales*.
<https://sitiooj.poder-judicial.go.cr>
3. Suhong, K. et al. (2018). *Crime Analysis Through Machine Learning*. IEEE IEMCON.
4. Supabase. (s/f). <https://supabase.com>